DE LA SOLUCIÓN AL IMPACTO

Plataforma de extracción semántica de reglas de negocio y especificación asistida por IA

Legacy-to-Cloud Modernization

PoC G2 aprobado → Industrialización G3 → Escalado sostenible G4

La decisión ejecutiva: escalar a nivel corporativo

De una prueba de concepto validada a una capacidad industrial sostenible

EVIDENCIA TÉCNICA

Recall 91,2% · Precisión 86,5%
Ahorro de tiempo medido: 52%

VALOR DE NEGOCIO

ROI 192% · VAN US$ 200K
Payback: mes 12

PREPARACIÓN PARA ESCALAR

Legal, MLOps, costes y adopción con prerrequisitos validados

DICTAMEN FINAL: ESCALAR (GATE G4)

La solución reduce el trabajo no facturable de lectura de código, mantiene trazabilidad y convierte la asistencia de IA en especificaciones revisables y firmadas por el arquitecto humano.

Continuidad estratégica: de G2 a G4

G2 · PoC

US$ 20K

8 semanas

Validar hipótesis sobre 3 módulos históricos certificados

G3 · Operación

Pipeline productivo

Integración en flujo de trabajo, monitorización y control

G4 · Escalado

2 → 16 módulos/año

Industrialización corporativa sin crecimiento lineal de plantilla senior

Marco de referencia: B3. Arquitectura, Desarrollo y Operación de Soluciones de IA

Referencias conceptuales: Huyen (2022); Sculley et al. (2015); Breck et al. (2017); Amershi et al. (2019).

Data Readiness Assessment

Plantilla 1 adaptada: valoración de los activos necesarios para operar el pipeline semántico

Caso: extracción semántica de código legacy | Owner: Lead Enterprise Architect & AI Data Lead | Objetivo: inferencia trazable y sin sesgo

Dimensión	Evidencia / riesgo clave	Valoración
Fuentes y disponibilidad	Repositorios Git con COBOL, copybooks y JCL	4 · Sólido
Accesibilidad	Cláusula de no-retención y tenant dedicado	3 · Aceptable
Calidad de datos	Código sintácticamente determinista; macros de terceros faltantes	4 · Sólido
Granularidad	Línea, PERFORM, bloques de control, SQL/VSAM	5 · Listo
Frecuencia y latencia	Batch/asíncrono por módulo; no requiere milisegundos	4 · Sólido
Linaje y trazabilidad	Git commit vinculado a AST y chunks del grafo	4 · Sólido
Representatividad	Dialectos antiguos subrepresentados en prompts estándar	3 · Aceptable
Ground truth	3 módulos históricos certificados como reglas doradas	4 · Sólido
Training vs. producción	Preprocesamiento AST estandarizado en inferencia	4 · Sólido

FORTALEZAS

Código estructurado y trazable

GAPS

Privacidad legal (R1) y dialectos/macros (R2)

SIGUIENTE DECISIÓN

Ingesta automatizada en Azure/VPC privada

Del modelo aislado a la solución industrializada

PoC · Gate G2

- Script de inferencia y prompts ad hoc
- Ingesta manual de fragmentos COBOL/JCL
- Evaluación offline en 3 módulos espejo
- Salida en texto plano / Markdown volátil
- Sin monitorización ni control de costes

Producción · G3/G4

- Pipeline CI/CD/CT automatizado y linaje end-to-end
- Parser AST y grafo de conocimiento
- Integración CLI/IDE, Jira y Azure DevOps
- Especificaciones auditables: OpenAPI + Gherkin
- Telemetría de tokens, latencia, drift y fallbacks

La solución industrializada convierte predicciones en decisiones operativas auditables dentro de un sistema sociotécnico.

AI Solution Architecture Canvas

Plantilla 2 adaptada: flujos desacoplados de preparación/indexación e inferencia/asistencia

1 · DATOS & PREPROCESAMIENTO

Repositorios COBOL/JCL/DDL
Parser AST multidialecto
Extractor de linaje → Vector/Graph Store

2 · MODELO & RAZONAMIENTO

Orquestador RAG
Prompt Engine (Gherkin/DDD)
LLM privado: Azure OpenAI / Claude VPC

3 · SERVICIO & DESPLIEGUE

FastAPI Worker batch/asíncrono
Celery/Redis para tareas
Generador OpenAPI v3.0 y tablas Markdown

4 · INTEGRACIÓN & CONSUMO

CLI corporativo / extensión VS Code
Jira / Azure DevOps: historias y trazas
Confluence: documentación certificada

5 · SUPERVISIÓN & OPERACIÓN

Human-in-the-loop: revisión de confianza
Telemetría: tokens, latencia y feedback PO
Banderas de confianza y fallbacks

CAPAS TRANSVERSALES: Zero-Retention · Gobierno · OpenTelemetry · Trazabilidad Git/DVC · Aislamiento criptográfico

Decisiones de diseño que hacen viable la operación

Diseñar desde la decisión

La salida alimenta el checklist de aprobación del arquitecto.

Separar ingesta e inferencia

Evita bloquear el IDE al indexar millones de líneas.

Zero-Retention

No persistir ni usar datos del cliente para reentrenamiento.

Patrón de servicio: un módulo de 50K LOC se procesa de forma robusta en 5–15 minutos con notificación de entrega; no se exige una respuesta interactiva en 2 segundos.

Parser sintáctico AST preserva dependencias semánticas en PERFORM, CALL y sentencias SQL/VSAM.

Baseline, métricas y criterios de aceptación

Separar rendimiento del modelo, sistema, operación y resultado de negocio

Nivel / métrica	Baseline	Target	Gate G2/G3
Recall / cobertura de reglas	Manual ≈ 65%	Target ≥ 90%	Crítico ≥ 85%
Precisión semántica	Manual ≈ 80%	Target ≥ 85%	Aceptación ≥ 80%
Procesamiento por módulo	8 semanas humano	Target < 30 min batch	< 60 min por 50K LOC
Reducción neta del ciclo	8 semanas	Target 3 semanas (−62%)	≥ 40% (4,8 semanas)
Defectos UAT por omisión	45% del total	Target < 5% (−70%)	≤ 15%

Racional operativo: los falsos negativos generan defectos tardíos; las reglas alucinadas aumentan la revisión senior; el ahorro de ciclo debe descontar validación humana.

Plan MLOps: CI / CD / CT

Flujo continuo adaptado a arquitecturas RAG/LLM

1 · CONTINUOUS INTEGRATION (CI)

- Linting y parsing COBOL
- Unit tests de parser AST y generadores OpenAPI
- Regresión semántica sobre 3 módulos Ground Truth

2 · DELIVERY / DEPLOYMENT (CD)

- Docker en Kubernetes privado
- Canary / Shadow para comparar concordancia
- Rollback inmediato si cae la precisión

3 · CONTINUOUS TUNING (CT)

- No reentrenar el modelo base
- Actualizar grafo de dependencias
- Incorporar ejemplos few-shot desde correcciones en Jira

Principio: evolucionar contexto, prompts y pipeline con control de versiones; evitar degradación y costes excesivos del reentrenamiento.

Monitorización de drift: detectar, diagnosticar y actuar

Ciclo de control inspirado en NIST AI RMF y Huyen (2022)

1 · MONITOR
Telemetría de inferencia y feedback humano

→

2 · DETECT
Anomalías, rechazo o degradación

→

3 · DIAGNOSE
Código, dialecto o modelo subyacente

→

4 · DECIDE
Estrategia de corrección

→

5 · ACT
Intervención segura y controlada

SEÑALES DE ALERTA

- Macros desconocidas / CICS atípico
- Rechazo o modificación senior >25%
- Tokens por módulo >10% del margen

DIAGNÓSTICO

- Dialecto no soportado por AST
- Cambio de proveedor que afecta JSON/OpenAPI

RESPUESTA SEGURA

- Aislar bloque: “Análisis Manual Requerido”
- Añadir correcciones validadas al vector store

Deuda técnica y sostenibilidad

Evitar costes ocultos acumulativos (Sculley et al., 2015)

Tipo de deuda	Riesgo	Mitigación
Deuda de datos	Formato legacy con saltos de columna COBOL área A/B	Normalizador estricto antes de inyectar contexto
Glue code / junglas de pipeli	Scripts dispersos en notebooks	Librería unificada de ingeniería inversa: rev-eng-core
Deuda de configuración	Temperatura, top_p y versiones de prompts sin control	Versionado formal en Git / MLflow

Sostenibilidad = componentes reutilizables + configuración versionada + cambios reversibles.

De valor esperado a valor realizado: resultados del PoC

Resultados tras 8 semanas y una inversión de US$ 20K en 3 módulos certificados

91,2%

Recall / cobertura

Supera target de 90%

86,5%

Precisión semántica

Supera target de 85%

52%

Ahorro de tiempo

Supera umbral crítico de 40%

Las hipótesis críticas de cobertura semántica y reducción del ciclo quedan respaldadas por evidencia observable.

Los resultados de laboratorio deben consolidarse en operación real con monitorización y supervisión humana.

Prevención de fuga de valor (Value Leakage)

Riesgos que pueden erosionar ahorro, adopción y margen

Fuente de fuga	Impacto potencial	Acción de contención
Doble verificación paranoica	Pérdida del 35% del ahorro estimado	Enlaces directos a líneas de código; revisar solo banderas de duda.
Brecha de adopción operativa	ROI podría caer de 192% a <40%	Integrar IA en CLI y Jira; no cotizar >4 semanas de análisis por módulo.
Inflación de costes de inferencia	Hasta US$ 15K/año en consumo cloud	Cache semántico y modelos ligeros para tareas sintácticas/AST.

La adopción y el diseño del flujo de trabajo son tan importantes como la precisión del modelo.

Benefits Realization Plan: de capacidad IA a resultado P&L

CAPACIDAD IA

Extracción semántica y trazabilidad a código

→

KPI OPERATIVO

Análisis de 8 a 3 semanas (−62,5% por módulo)

→

IMPACTO EN PROYECTO

320 horas liberadas por módulo

→

RESULTADO P&L

US$ 248.000 de ahorro anual en margen bruto

EFECTO EN CALIDAD

Defectos UAT por omisión: 45% → 12% en piloto (target final <5%).

EFECTO EN CAPACIDAD

Eliminación de semanas de retrabajo; capacidad de absorción: +40% proyectos ganados.

Atribución causal: comparación con baseline histórico de 8 semanas y US$ 3.875 por semana de squad.

Adopción y gestión del cambio: modelo ADKAR

El objetivo es que la IA quite tareas tediosas y amplifique el criterio experto

Fase	Palanca operativa	Métrica de adopción
A · Awareness	Mostrar que el 45% de bugs UAT nace del análisis manual	100% Tech Leads en sesiones
D · Desire	IA como asistente, no rival; foco en diseño DDD	NPS interno ≥ +40
K · Knowledge	Formación en validación crítica, alucinaciones y prompts	100% arquitectos certificados
A · Ability	Coaching en el primer módulo productivo real	Primer ciclo ≤ 4 semanas
R · Reinforcement	Checklist IA en Definition of Ready mandatorio	≥80% portfolio analizado

Barreras a gestionar: miedo a la irrelevancia del experto y sesgo de automatización (confianza ciega o rechazo visceral).

El punto de decisión real del arquitecto

La adopción ocurre al revisar y firmar la especificación, no al generar el reporte

RECHAZO / DESCONFIANZA

- Relee código manualmente
- Vuelve a revisar hasta 50.000 líneas
- Consume 6–8 semanas
- Retrabajo y coste alto

ADOPCIÓN EFECTIVA

- Confía en linaje y enlaces a fuente
- Revisa banderas de baja confianza
- Ajusta y firma en 3 semanas
- Genera el valor prometido

PALANCAS FACILITADORAS

Ver código fuente

Resalta las 12 líneas que originan cada regla.

Confianza semafórica

Verde: alta · Ámbar: ambigua · Rojo: manual.

Firma humana

El arquitecto conserva la responsabilidad final.

Gobierno de IA: roles, controles y accountability

Estructura inspirada en NIST AI RMF e ISO/IEC 42001

Actividad / decisión	AI Transformation Lead	Lead Architect	CISO / Legal	Squad Dev
Autorización de uso de código	C	I	A/R	I
Aprobación de prompts/modelo	A	R	C	I
Firma de especificación funcional	I	A/R	I	C
Paso a producción (CI/CD)	R	C	A	I
Auditoría de fuga / tokens	A	I	R	I

Accountability indeleble: la firma de la especificación funcional y el contrato OpenAPI corresponde legal y profesionalmente al Lead Architect humano.

R = ejecuta · A = aprobador final · C = consultado · I = informado

Scale Readiness Checklist

Plantilla 3 adaptada: prerrequisitos previos a expandir a todo el portfolio

Fase / criterio	Evidencia / documentación	Estado
Madurez de datos	Parser AST validado con 96,4% de sentencias COBOL/JCL en 3 entornos	LISTO
Gobierno legal	Zero-Data Retention y VPC aprobadas por Legal; R1 mitigado	LISTO
Automatización MLOps	CI/CD operativo con testing semántico automatizado en staging	LISTO
Sostenibilidad económica	US$ 8,50 por 10K LOC; 5,2% del ahorro (guardrail 15%)	LISTO
Gestión del cambio	2 squads piloto; ciclo −48%; NPS técnico +44	LISTO



5 de 5 prerrequisitos validados para el escalado corporativo.

DECISIÓN FINAL · GATE G4

ESCALAR A NIVEL CORPORATIVO

01	**Evidencia empírica**	Recall ≥90% y reducción neta del ciclo ≥40% superan umbrales.
02	**Caso de negocio validado**	VAN US$ 200K · ROI 192% · Payback en mes 12.
03	**Riesgo legal controlado**	Entornos privados y Zero-Data Retention aprobados.
04	**Sostenibilidad técnica**	Arquitectura desacoplada permite pasar de 2 a 16 módulos anuales.

Escalar con supervisión humana, monitorización continua y disciplina MLOps.

Referencias y marco conceptual

- Huyen (2022): diseño, operación y monitorización de sistemas de machine learning.
- Sculley et al. (2015): deuda técnica oculta en sistemas de machine learning.
- Breck et al. (2017): pruebas y preparación para producción en sistemas ML.
- Amershi et al. (2019): prácticas de ingeniería de software para sistemas de ML.
- NIST AI RMF e ISO/IEC 42001: marcos de gobierno y gestión de riesgos de IA.

Mensaje final: el impacto se realiza cuando la capacidad técnica se integra al proceso, es adoptada por las personas y produce resultados auditables.